Министерство транспорта Российской Федерации

Федеральное государственное автономное образовательное учреждение

высшего образования «Российский университет транспорта»

(РУТ (МИИТ))

Институт железнодорожного транспорта

Кафедра «Цифровые технологии управления транспортными процессами»

Практическая работа №1

По предмету «Сбор, хранение и обработка больших данных»

На тему «Знакомство с экосистемой Hadoop.

Установка, настройка и базовое администрирование»

Выполнил: Груздева К.А.

Группа: ЦИИ-171

Проверил: Кухтинов А. Э.

Москва 2026 г.

Оглавление

1. Цель и задачи работы 3

2. Ход выполнения 3

3. Ответы на контрольные вопросы 6

4. Выводы 7

1. Цель и задачи работы

Цель работы: получить практический опыт установки Hadoop в псевдо-распределенном режиме, изучить его веб-интерфейсы и понять базовые принципы работы с HDFS.

Задачи:

1. Установить виртуальную машину и настроить окружение.
2. Установить Apache Hadoop в псевдо-распределенном режиме.
3. Запустить кластер и изучить веб-интерфейсы NameNode и ResourceManager.
4. Выполнить базовые операции с HDFS.
5. Создать подробный отчет о проделанной работе.

2. Ход выполнения

На первом этапе была произведена установка Apache Hadoop версии 3.3.6 в псевдо-распределенном режиме на виртуальную машину с Ubuntu Server 22.04. Для проверки корректности установки была выполнена команда hadoop version.

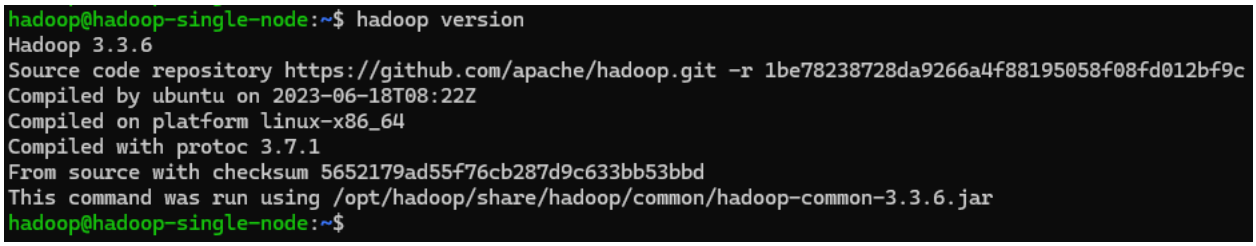


Рисунок 1 – Результат выполнения команды hadoop version

После настройки конфигурационных файлов был произведен запуск демонов HDFS и YARN с помощью скриптов start-dfs.sh и start-yarn.sh. Для проверки того, что все необходимые процессы запущены, была использована команда jps.

```
hadoop@hadoop-single-node:/opt/hadoop/etc/hadoop$ jps
2994 Jps
2132 DataNode
2535 ResourceManager
2664 NodeManager
1999 NameNode
2351 SecondaryNameNode
hadoop@hadoop-single-node:/opt/hadoop/etc/hadoop$
```

Рисунок 2 – Список работающих демонов Hadoop

Для мониторинга состояния HDFS был открыт веб-интерфейс NameNode по адресу http://192.168.3.20:9870. На главной странице отображается общая информация о кластере: версия Hadoop, время запуска, объем хранилища, а также список живых DataNode.

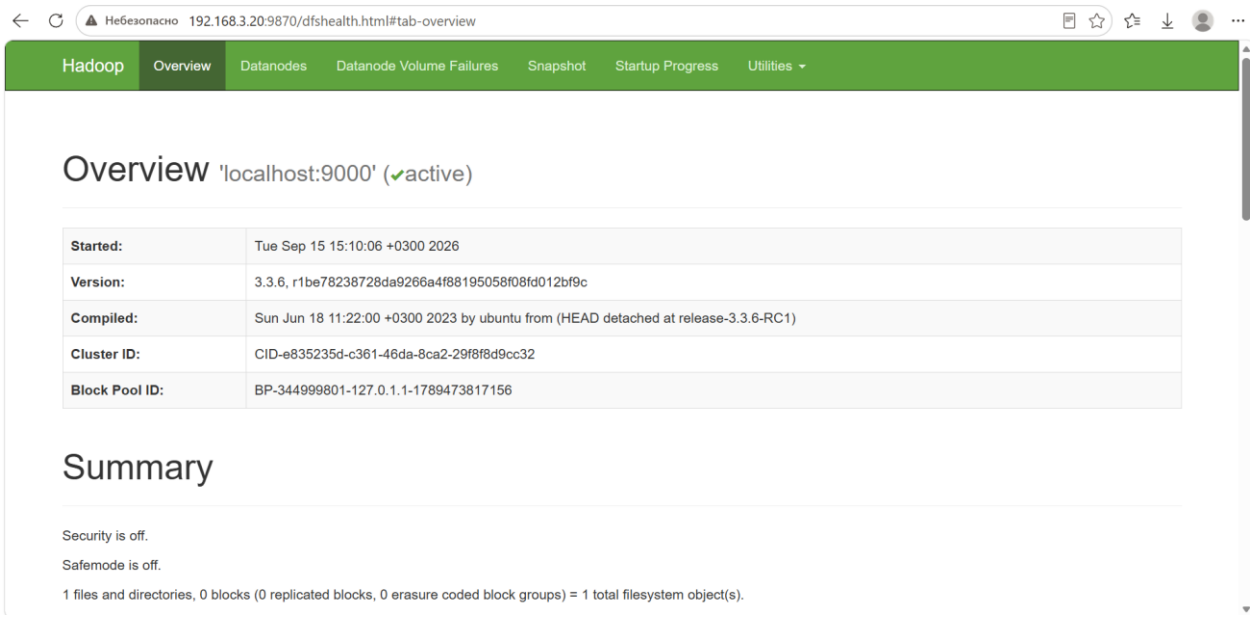


Рисунок 3 – Веб-интерфейс NameNode (порт 9870)

Для мониторинга ресурсов YARN был открыт веб-интерфейс ResourceManager по адресу http://192.168.3.20:8088. На странице отображаются метрики кластера: доступная и используемая память, количество ядер CPU, а также список запущенных приложений.

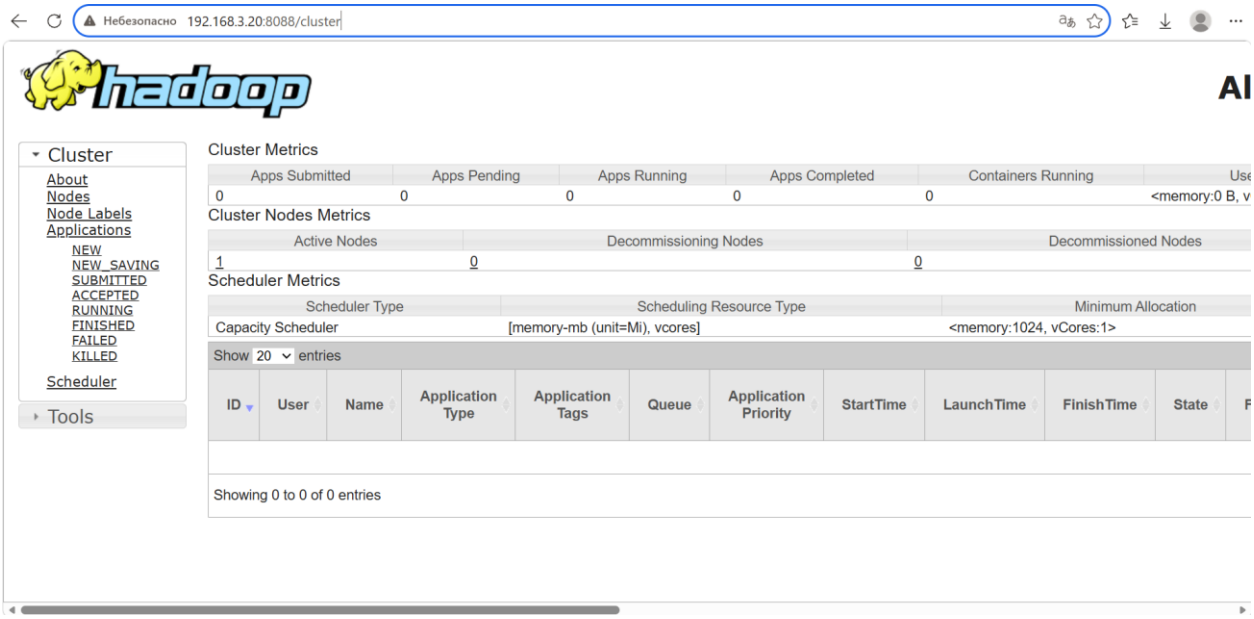


Рисунок 4 – Веб-интерфейс ResourceManager (порт 8088)

Для проверки работы файловой системы HDFS был выполнен ряд базовых команд: просмотр содержимого корневой директории (ls), создание новой директории (mkdir), загрузка локального файла в HDFS (put) и просмотр содержимого файла (cat).

```
hadoop@hadoop-single-node:/opt/hadoop/etc/hadoop$ hdfs dfs -ls /
Found 6 items
drwxr-xr-x   - hadoop supergroup          0 2026-09-15 12:17 /data
drwxr-xr-x   - hadoop supergroup          0 2026-09-15 12:18 /input
drwxr-xr-x   - hadoop supergroup          0 2026-09-15 12:20 /output
drwxr-xr-x   - hadoop supergroup          0 2026-09-15 12:18 /test
drwxr-xr-x   - hadoop supergroup          0 2026-09-15 12:19 /tmp
drwxr-xr-x   - hadoop supergroup          0 2026-09-15 12:16 /user
```

Рисунок 5 – Результат выполнения команды hdfs dfs -ls / (просмотр корневой директории HDFS)

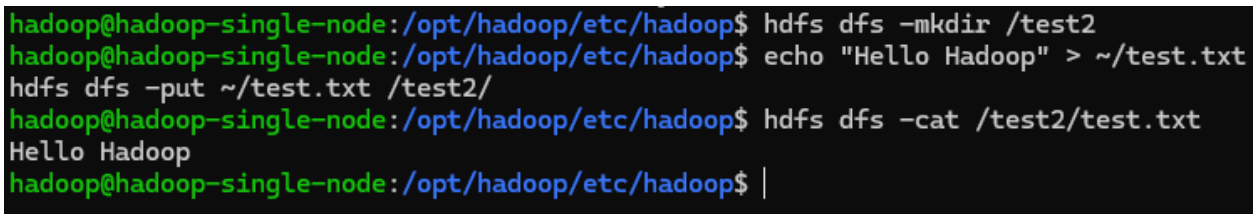


Рисунок 6 – Выполнение команд mkdir (создание папки /test2), put (загрузка файла test.txt) и cat (просмотр содержимого файла)

3. Ответы на контрольные вопросы

1. Режим standalone (локальный) отличается тем, что все демоны Hadoop работают в одном Java-процессе. Это не является распределенной системой, и такой режим используется преимущественно для отладки кода MapReduce или Spark. В свою очередь, режим pseudo-distributed (псевдо-распределенный) подразумевает, что каждый демон Hadoop (NameNode, DataNode, ResourceManager, NodeManager и другие) запускается как отдельный процесс Java. Это позволяет эмулировать работу полноценного кластера на одной машине и используется для обучения и тестирования полного цикла работы Hadoop.

2. Из веб-интерфейса NameNode можно получить общую информацию о кластере, включая версию Hadoop и время его запуска. Также там отображается объем хранилища (общий, использованный и свободный), количество живых (Live) и мертвых (Dead) узлов DataNode. Кроме того, через вкладку Utilities → Browse the file system можно просмотреть содержимое файловой системы HDFS.

3. Веб-интерфейс ResourceManager отображает метрики кластера: доступную и используемую оперативную память, а также количество ядер CPU. Кроме того, на странице представлен список запущенных, завершенных и ожидающих приложений (Applications), а также информация о доступных NodeManager'ах (узлах).

4. Процесс копирования файла в HDFS начинается с того, что клиент обращается к NameNode с запросом на создание нового файла. NameNode проверяет права доступа и возвращает список DataNode, на которых будут храниться блоки файла. Затем клиент разбивает файл на блоки (обычно по 128 МБ) и отправляет их напрямую на выбранные DataNode. Каждый DataNode сохраняет блоки и реплицирует их в соответствии с заданным фактором репликации (в нашем случае replication=1, поэтому дополнительные копии не создаются). После успешной записи всех блоков клиент уведомляет NameNode о завершении операции.

4. Выводы

В ходе работы я освоил установку Hadoop в псевдо-распределенном режиме. Основная сложность возникла на этапе настройки SSH-доступа без пароля, так как без него скрипты запуска не работают. Также потребовалось время на настройку сетевого моста в VirtualBox для доступа к веб-интерфейсам. Я получил навыки работы с командной строкой HDFS и понял архитектуру взаимодействия NameNode и DataNode.